

# 奇异值分解

## 1.奇异值分解的定义与性质

### 1.1 奇异值分解的定义：

**定义 (奇异值分解)：**

矩阵的奇异值分解是指，任何一个非零 $m \times n$ 实数矩阵 $A$ 都可以表示为以下三个矩阵的乘积的形式，即矩阵的因子分解：

$$A = U\Sigma V^T \quad (1)$$

其中， $U$ 是 $m$ 阶正交矩阵， $V$ 是 $n$ 阶正交矩阵， $\Sigma$ 是由降序排列的非负对角元素组成的 $m \times n$ 对角矩阵。满足：

$$UU^T = I \quad (2)$$

$$VV^T = I \quad (3)$$

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p) \quad (4)$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0 \quad (5)$$

$$p = \min(m, n) \quad (6)$$

$U\Sigma V^T$ 称为矩阵 $A$ 的奇异值分解， $\sigma_i$ 称为 $A$ 的奇异值， $U$ 的列向量称为左奇异向量， $V$ 的列向量称为右奇异向量。

### 1.2 奇异值分解的计算：

给定 $m \times n$ 阶矩阵 $A$ ，可以根据以下步骤计算出其奇异值分解：

1. 计算出 $n$ 阶对称矩阵 $W = A^T A$

求出 $W$ 的特征值 $\lambda_i$ 并且从大到小排列：

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0 \quad (7)$$

根据特征值分别求出特征向量并单位正交化，得到特征向量：

$$v_i, Wv_i = \lambda_i v_i, i = 1, 2, \dots, n \quad (8)$$

2. 求正交矩阵 $V$ ：

若特征值中非零个数为 $r$ ，即：

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0, \lambda_{r+1} = \lambda_{r+2} = \dots = \lambda_n = 0 \quad (9)$$

令：

$$V_1 = [v_1 \ v_2 \ \dots \ v_r], V_2 = [v_{r+1} \ v_{r+2} \ \dots \ v_n] \quad (10)$$

$$V = [V_1 \ V_2] \quad (11)$$

则有：

$$A = AVV^T = AV_1V_1^T + AV_2V_2^T = AV_1V_1^T \quad (12)$$

3.

4. 求  $m \times n$  矩阵  $\Sigma$ :

令  $\sigma_i = \sqrt{\lambda_i}$ , 则有:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0, \sigma_{r+1} = \sigma_{r+2} = \dots = \sigma_n = 0 \quad (13)$$

令:

$$\Sigma_1 = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r) \quad (14)$$

$$\Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix} \quad (15)$$

5. 求正交矩阵  $U$ :

令:

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \dots, r \quad (16)$$

$$U_1 = [u_1 \ u_2 \ \dots \ u_r] \quad (17)$$

则:

$$A U_1 = U_1 \Sigma_1 \quad (18)$$

求  $A^T$  的零空间  $N(A^T)$  的一组标准正交基  $\{u_{r+1}, u_{r+2}, \dots, u_m\}$ , 令:

$$U_2 = [u_{r+1} \ u_{r+2} \ \dots \ u_m] \quad (19)$$

则:

$$U = [U_1 \ U_2] \quad (20)$$

5. 得到奇异值分解:

$$A = U \Sigma V^T \quad (21)$$

### 1.3 紧奇异值分解与截断奇异值分解

上面的过程得到的奇异值分解称为完全奇异值分解:

1. **紧奇异值分解:**

$$A = U_r \Sigma_r V_r^T \quad (22)$$

其中,  $U_r$  是由  $U$  的前  $r$  列构成的  $m \times r$  矩阵,  $\Sigma_r$  是由  $\Sigma$  前  $r$  行和  $r$  列构成的  $r \times r$  对角矩阵,  $V_r$  是由  $V$  前  $r$  列构成的  $n \times r$  矩阵。

2. **截断奇异值分解:**

$$A = U_k \Sigma_k V_k^T, \quad 0 < k < r \quad (23)$$

其中,  $U_k$  是由  $U$  的前  $k$  列构成的  $m \times k$  矩阵,  $\Sigma_k$  是由  $\Sigma$  前  $k$  行和  $k$  列构成的  $k \times k$  对角矩阵,  $V_k$  是由  $V$  前  $k$  列构成的  $n \times k$  矩阵。

## 1.4 几何解释


如果将  $m \times n$  矩阵  $A$  看成是一个  $n$  维空间  $R^n$  到  $m$  维空间  $R^m$  的一个线性变换，即：

$$x \in R^n, Ax \in R^m \quad (24)$$

奇异值分解的几何意义就是，任何一个线性变换都可以分解为三个简单的变换：

1. 一个左边系的旋转或反射： $x \rightarrow V^T x$
2. 一个坐标轴的缩放变换： $V^T x \rightarrow \Sigma V^T x$
3. 另一个坐标系的旋转或反射变换： $\Sigma V^T x \rightarrow U \Sigma V^T x$

如下图示：



$$M = U \cdot \Sigma \cdot V^*$$

## 2. 奇异值分解与矩阵近似

奇异值分解也是一种矩阵近似的方法，这个近似在弗罗贝尼乌斯范数意义下的近似，矩阵的弗罗贝尼乌斯范数是向量  $L_2$  范数的推广，对应着机器学习中的平方损失函数。

### 2.1 弗罗贝尼乌斯范数

**定义 (弗罗贝尼乌斯范数)：**

设矩阵  $A \in R^{m \times n}$ ， $A = [a_{ij}]_{m \times n}$ ，定义矩阵  $A$  的弗罗贝尼乌斯范数为：

$$\|A\|_F = \left( \sum_{i=1}^m \sum_{j=1}^n (a_{ij})^2 \right)^{\frac{1}{2}} \quad (25)$$

**引理：**

设矩阵  $A \in R^{m \times n}$ ，其奇异值分解为  $U \Sigma V^T$ ，其中  $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ ，则：

$$\|A\|_F = (\sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)^{\frac{1}{2}} \quad (26)$$

## 2.2 矩阵的最优近似

奇异值分解是在平方损失意义下，对矩阵的最优近似，即数据压缩

**定理：**

设矩阵  $A \in R^{m \times n}$ ，矩阵的秩  $\text{rank}(A) = r$ ，并设  $M$  为  $R^{m \times n}$  中所有秩不超过  $k$  的矩阵集合， $0 < k < r$ ，则存在一个秩为  $k$  的矩阵  $X \in M$ ，使得：

$$\|A - X\|_F = \min_{S \in M} \|A - S\|_F \quad (27)$$

称矩阵  $X$  为矩阵  $A$  在弗罗贝尼乌斯范数意义下的最优近似。

**定理：**

设矩阵  $A \in R^{m \times n}$ ，有奇异值分解  $A = U\Sigma V^T$ ，矩阵的秩  $\text{rank}(A) = r$ ，并设  $M$  为  $R^{m \times n}$  中所有秩不超过  $k$  的矩阵集合， $0 < k < r$ ，若一个秩为  $k$  的矩阵  $X \in M$  满足：

$$\|A - X\|_F = \min_{S \in M} \|A - S\|_F \quad (28)$$

则有：

$$\|A - X\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}} \quad (29)$$

特别的，若  $A' = U\Sigma'V^T$ ，其中：

$$\Sigma' = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix} \quad (30)$$

则有：

$$\|A - A'\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}} = \min_{S \in M} \|A - S\|_F \quad (31)$$

所以，紧奇异值分解是在弗罗贝范数意义下对矩阵的无损压缩，截断奇异值分解是有损失的压缩。截断奇异值分解得到的矩阵的秩为  $k$ ，通常远小于原始矩阵的秩  $r$ ，所以是由低秩矩阵实现了对原始矩阵的压缩。